



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین شماره دو

دانشجویان:

سوال یک: رضا مردانی شماره دانشجویی: ۶۱۰۳۰۱۱۸۰

سوال دو: احمد رضا نوپوش شماره دانشجویی ۶۱۰۳۰۱۱۹۴

فهرست مطالب

۳	فهرست تصاویر
۴	فهرست جداول
۵	۱ سگمنتیشن بافت‌های مغزی
۲۱	۲ تشخیص وسائل نقلیه با استفاده از Faster-RCNN بهبود یافته
۲۱	۱-۲ معماری مقاله
۲۳	۲-۲ سوالات نظری
۲۳	۱-۲-۲ تفاوت NMS و Soft-NMS چیست؟
۲۴	۲-۲-۲ مزایا و معایب استفاده از Mobilenet در مقابل VGG16
	۳-۲-۲ معماری Context-aware RoI Pooling نسبت به RoI Pooling چه مشکلی را
۲۵	حل می‌کند؟
۲۶	۳-۲ پیش‌پردازش داده‌ها
۲۸	۴-۲ آموزش روی مدل Faster-RCNN پایتورچ و نتایج
۲۸	۱-۴-۲ فرآیند آموزش
۲۸	۲-۴-۲ تحلیل نتایج
۳۲	۳-۴-۲ جمع‌بندی

فهرست تصاویر

۲۷		۱	داده خام
۲۷		۲	داده پیش پردازش شده
۲۹		۳	نمودار کاهش خطا
۲۹		۴	نمودار @MAP ۵۰
۳۰		۵	مقایسه پاسخ مدل با برجسب واقعی
۳۱		۶	مقایسه پاسخ مدل با برجسب واقعی

فهرست جداول

۱	میانگین معیارهای ارزیابی برای هر کلاس بافت مغزی در پایان اپوک دهم	۱۷
۲	مقایسه NMS و Soft-NMS در مرحله پس پردازش RPN	۲۴
۳	مقایسه مدل MobileNet با مدل VGG	۲۴

۱ سگمنتیشن بافت‌های مغزی

۱-۱-۱

آماده‌سازی داده‌ها و تحلیل روش مبتنی بر پچ (Patch-Based)

در این بخش، تمامی مراحل آماده‌سازی داده‌ها که در کد پیاده‌سازی شده‌اند، به‌صورت گام‌به‌گام توضیح داده می‌شوند. سپس روش آموزش مبتنی بر پچ (Patch-Based) (Training) از دیدگاه پژوهشی بررسی شده و مزایا، محدودیت‌ها و دلایل استفاده از آن در مقاله تحلیل می‌گردد.

گام‌های انجام‌شده در آماده‌سازی داده‌ها

در کد، فرآیند آماده‌سازی داده‌ها مطابق مراحل زیر انجام می‌شود:

۱. شناسایی و تطبیق فایل‌ها (load_file_paths)

- انجام جستجوی بازگشتی در پوشه □ داده‌ها برای یافتن فایل‌های حجم مغز با الگوی:

`*ana_strip.nii.gz`

- ساختن نام فایل سگمنتیشن متناظر:

`*segTRI_fill_ana.nii.gz`

- اطمینان از وجود هر دو فایل تصویر و ماسک و تولید دو لیست هماهنگ از مسیرها.

*۲. بارگذاری حجم‌های سه‌بعدی

- فایل‌های تصویر و ماسک با استفاده از کتابخانه □ nibabel بارگذاری می‌شوند.

- ابعاد معمول حجم‌های دیتاست IBSR به صورت زیر است:

$$128 \times 256 \times 256$$

۳. استخراج اسلایس از سه محور برای هر یک از محورهای X ، Y و Z :

- اسلایس‌ها از اندیس ۱۰ و با گام ۳ انتخاب می‌شوند.
- تعداد اسلایس‌های استخراج‌شده از هر محور به ۴۸ عدد محدود می‌شود.

در نتیجه:

$$\text{اسلایس برای هر بیمار} \quad 48 \times 3 = 144$$

برای هر اسلایس:

- بعد تک‌بعدی (singleton) (axis) حذف می‌شود،
 - اسلایس ۹۰ درجه چرخانده می‌شود تا جهت‌گیری تمام اسلایس‌ها یکسان گردد.
- *۴. پد کردن اسلایس‌ها به اندازه ثابت 256×256 به دلیل تفاوت ابعاد اسلایس‌ها در محورهای مختلف، همگی با پدینگ مرکزی به ابعاد ثابت زیر تبدیل می‌شوند:

$$256 \times 256$$

۵. استخراج پیچ‌های 128×128 هر اسلایس 256×256 به چهار پیچ غیرهم‌پوشان تقسیم می‌شود:

$$128 \times 128$$

موقعیت پیچ‌ها:

$$(0 : 128, 0 : 128), (0 : 128, 128 : 256), (128 : 256, 0 : 128), (128 : 256, 128 : 256)$$

بنابراین تعداد پیچ‌های تولیدشده برای هر بیمار:

$$\text{پیچ} \quad 576 = \text{پیچ} \quad 4 \times \text{اسلایس} \quad 144$$

۶. تبدیل به تانسورهای PyTorch

- تصویر به صورت:

$$1 \times 128 \times 128$$

- ماسک به صورت:

$$128 \times 128$$

تغییرات ابعادی داده‌ها

مرحله	ابعاد تصویر	توضیح
حجم اولیه ^۳ بعدی	$256 \times 256 \times 128$	شکل خام داده
اسلایس ^۲ بعدی	$\approx 256 \times 256$	اسلایس استخراج‌شده از یکی از محورها
پس از پدینگ	256×256	یکسان‌سازی ابعاد
پچ استخراج‌شده	128×128	تقسیم هر اسلایس به چهار پچ
تانسور نهایی	$1 \times 128 \times 128$	قابل استفاده در شبکه عصبی ^۱

روش Training: Patch-Based معرفی پژوهشی

در روش Patch-Based، به‌جای آموزش شبکه با کل تصویر، مدل روی نواحی کوچک‌تر و ثابت اندازه (پچ‌ها) آموزش داده می‌شود. این رویکرد در پژوهش‌های اولیه^۱ مبتنی بر CNN در تصویربرداری پزشکی (۲۰۱۴ تا ۲۰۱۶) بسیار رایج بود و برای مجموعه‌های کوچک مانند IBSR مزیت‌های قابل‌توجهی دارد. دو دسته^۲ اصلی این روش عبارت‌اند از:

۱. **Classification Patch**: پیش‌بینی برچسب پیکسل مرکزی پچ.

۲. **Segmentation Patch**: تولید نقشه^۳ سگمنتیشن برای کل پچ (روش استفاده‌شده در کد حاضر).

مزایا

- افزایش قابل توجه حجم داده:

نمونه ۴ → هر اسلایس

- کاهش مصرف حافظه GPU و امکان استفاده از مدل‌های عمیق‌تر.
- تقویت یادگیری ویژگی‌های محلی مانند مرزها و ساختارهای ظریف بافتی.
- کاهش احتمال بیش‌برآزش به‌ویژه در مجموعه‌های کوچک.

معایب

- از دست رفتن اطلاعات کلی تصویر: پچ‌ها تنها محدوده محلی را پوشش می‌دهند.
- احتمال بروز ناپیوستگی در مرزهای سگمنتیشن هنگام بازسازی تصویر کامل.
- نیاز به نمونه‌برداری هدفمند: جلوگیری از غلبه پچ‌های مربوط به پس‌زمینه.
- افزایش پیچیدگی مرحله بیش‌برآزش.

دلایل استفاده از روش Patch-Based در مقاله

روش Patch-Based در این نوع پژوهش‌ها معمولاً به دلایل زیر به‌کار گرفته می‌شود:

۱. کوچک بودن مجموعه IBSR: وجود تنها ۱۸ بیمار باعث می‌شود آموزش با تصویر کامل مستعد بیش‌برآزش باشد.
۲. محدودیت حافظه GPU: آموزش با پچ‌ها سبک‌تر، پایدارتر و کم‌هزینه‌تر است.
۳. بهبود دقت در مرزها و ساختارهای کوچک: مانند لایه‌های ماده خاکستری و سفید.
۴. جایگاه تثبیت‌شده این روش در پژوهش‌های سگمنتیشن MRI: کاربردی و قابل اعتماد در مطالعات اولیه.

۲-۱-۱

آمار داده‌های آموزشی و اعتبارسنجی

پس از انجام مراحل آماده‌سازی و استخراج پچ‌ها، مجموعه داده به دو بخش آموزش و اعتبارسنجی تقسیم شده است. تعداد حجم‌ها و پچ‌های هر بخش به صورت زیر است:

• حجم‌های آموزش: ۱۲ حجم سه‌بعدی


• تعداد پچ‌های آموزش: ۶۵۲۸ پچ



• حجم‌های اعتبارسنجی: ۶ حجم سه‌بعدی



• تعداد پچ‌های اعتبارسنجی: ۳۲۶۴ پچ



این توزیع باعث می‌شود مدل در مرحله آموزش از تعداد کافی نمونه‌های محلی (پچ‌ها) برای یادگیری ویژگی‌ها بهرمند شود، در حالی که بخش اعتبارسنجی نیز اندازه مناسبی برای ارزیابی عملکرد مدل در طول فرایند آموزش دارد.



۳-۱-۱











U-Net یکی از پر استفاده‌ترین معماری‌های یادگیری عمیق در حوزه سگمنتیشن تصاویر پزشکی است. این مدل برای اولین بار در سال ۲۰۱۵ معرفی شد و به دلیل توانایی بالایی آن در تولید نقشه‌های سگمنتیشن دقیق حتی با مجموعه داده‌های کوچک، به سرعت به یک معماری استاندارد در پژوهش‌های مرتبط تبدیل شد. معماری U-Net از دو بخش اصلی تشکیل شده است:

- **مسیر پایین‌رونده (Encoder):** این بخش شامل چندین لایه متوالی کانولوشن و بیش‌نمونه‌برداری (Pool-ing) است. در این مسیر، با کاهش تدریجی ابعاد فضایی تصویر و افزایش تعداد فیلترها، مدل می‌تواند ویژگی‌های معنایی و الگوهای سطح بالا را از تصویر استخراج کند. این قسمت مشخص می‌کند چیزی “چه در تصویر وجود دارد.

- **مسیر بالارونده (Decoder):** این بخش شامل لایه‌های افزایش وضوح (Upsampling) یا Transposed Convolution و کانولوشن است. در این مسیر، مدل تلاش می‌کند ساختارهای استخراج شده در Encoder را دوباره به فضای پیکسلی بازگرداند و نقشه سگمنتیشن را با دقت فضایی بالا بازسازی کند. این قسمت مشخص می‌کند “کجا” هر ساختار قرار دارد.

ویژگی کلیدی U-Net، **اتصالات میان‌بر (Skip Connections)** بین هر لایه Encoder و لایه متناظر در Decoder است. این اتصالات موجب می‌شود اطلاعات فضایی دقیق که در مراحل پایین‌رونده از دست رفته‌اند، مستقیماً به مراحل بالارونده منتقل شوند. در نتیجه:

- مرز اندام‌ها و ساختارهای ریز دقیق‌تر شناسایی می‌شوند؛
- مدل هم‌زمان هم **اطلاعات محلی** (لبه‌ها، مرزها) و هم **اطلاعات سراسری** (زمینه کلی تصویر) را یاد می‌گیرد؛
- مشکل محو شدن گرادیان کاهش یافته و فرایند آموزش پایدارتر می‌شود.

به طور خلاصه، ساختار Encoder-Decoder به همراه Skip Connection ها امکان می‌دهد که مدل، هم محتوای کلی تصویر و هم جزئیات ظریف آن را به‌طور هم‌زمان در نظر بگیرد؛ موضوعی که برای تولید نقشه‌های سگمنتیشن پیکسلی با دقت بالا ضروری است.

تعداد پارامترهای مدل

مدل پیادساز شده بر اساس معماری معرفی شده در مقاله دارای مقادیر زیر است:

• پارامترهای قابل آموزش (Trainable Parameters):

۷,۷۰۵,۴۷۶

• پارامترهای غیرقابل آموزش (Non-trainable Parameters):

.

این مقدار نشان می‌دهد که تمام اجزای مدل شامل لایه‌های کانولوشنی، لایه‌های افزایش وضوح و اتصال‌های تکمیلی، همگی در فرایند یادگیری مشارکت دارند و هیچ پارامتر ثابت یا فریز شده‌ای در ساختار مدل وجود ندارد

*۱-۳-۱

برای تحلیل کیفیت سگمنتیشن در مدل‌های یادگیری عمیق، از چند معیار مرسوم استفاده می‌شود که هر کدام جنبه متفاوتی از عملکرد مدل را نشان می‌دهند. در این بخش، معیارهای Dice، Jaccard (IoU)، Precision و Recall معرفی شده و نقش آن‌ها در ارزیابی مدل توضیح داده می‌شود.

۱. ضریب دایس (Dice Coefficient) ضریب دایس میزان همپوشانی بین نقشه سگمنتیشن پیش‌بینی شده و نقشه واقعی را اندازه‌گیری می‌کند و به‌صورت زیر تعریف می‌شود:

$$Dice = \frac{2TP}{2TP + FP + FN}.$$

مقدار این معیار بین صفر تا یک است و هرچه به یک نزدیک‌تر باشد، مدل همپوشانی دقیق‌تری با ناحیه واقعی ایجاد کرده است. ضریب دایس در ارزیابی کیفیت کلی سگمنتیشن، به‌ویژه در داده‌های پزشکی، یکی از مهم‌ترین معیارها محسوب می‌شود.

۲. شاخص جاکارد (Jaccard) / IoU معیار جاکارد یا Intersection over Union نیز میزان همپوشانی

را می‌سجد اما از دایس سخت‌گیرانه‌تر است:

$$IoU = \frac{TP}{TP + FP + FN}.$$

مقدار کمتر این معیار نسبت به دایس بیانگر حساسیت بیشتر آن به اشتباهات مدل است. این معیار درصد ناحیه $\square$ مشترک واقعی بین پیش‌بینی و حقیقت را نشان می‌دهد.

۳. **دقت (Precision)** معیار دقت مشخص می‌کند چه نسبت از پیکسل‌هایی که مدل به‌عنوان ناحیه $\square$ هدف تشخیص داده، واقعاً صحیح بوده‌اند:

$$Precision = \frac{TP}{TP + FP}.$$

اگر مقدار دقت پایین باشد، مدل پیکسل‌های زمینه را به اشتباه در ناحیه $\square$ هدف قرار می‌دهد که به Over-segmentation منجر می‌شود.

۴. **بازیابی (Recall)** بازیابی نشان می‌دهد چه مقدار از ناحیه $\square$ واقعی توسط مدل شناسایی شده است:

$$Recall = \frac{TP}{TP + FN}.$$

مقدار پایین بازیابی نشان می‌دهد که بخش‌هایی از ناحیه $\square$ واقعی از قلم افتاده‌اند که این حالت Under-segmentation نامیده می‌شود.

۵. **نقش معیارها در تحلیل عملکرد مدل** ترکیب این معیارها دیدی جامع از توانمندی مدل ارائه می‌دهد:

- ضریب دایس و جاکارد کیفیت هم‌پوشانی کلی را نشان می‌دهند.
- دقت منعکس‌کننده $\square$ میزان جلوگیری از پیش‌بینی‌های اشتباه است.
- بازیابی نشان می‌دهد مدل تا چه حد ناحیه $\square$ هدف را کامل پوشش داده است.

استفاده $\square$ هم‌زمان از این معیارها امکان تحلیل دقیق عملکرد مدل در بازسازی مرزها، شناسایی ساختارهای کوچک و جلوگیری از خطاهای اضافه یا کم‌پیش‌بینی را فراهم می‌کند.

نتایج آموزش و ارزیابی مدل

مدل پس از ۱۰ اپوک آموزش داده شد و معیارهای Precision، Recall، Jaccard و Dice برای هر کلاس بافت مغزی محاسبه گردید. نتایج میانگین برای کل مجموعه اعتبارسنجی و همچنین مقادیر هر کلاس در جدول زیر ارائه شده است.

جدول ۱: میانگین معیارهای ارزیابی برای هر کلاس بافت مغزی در پایان اپوک دهم

Dice	Jaccard	Recall	Precision	کلاس
۹۹۸۵.۰	۹۹۷۰.۰	۹۹۷۳.۰	۹۹۹۷.۰	Background
۶۳۴۰.۰	۴۶۴۱.۰	۹۳۴۲.۰	۴۷۹۸.۰	CSF
۸۲۲۵.۰	۶۹۸۵.۰	۷۶۹۷.۰	۸۸۳۱.۰	GM
۸۵۰۰.۰	۷۳۹۱.۰	۸۷۴۰.۰	۸۲۷۳.۰	WM


تحلیل نتایج


با توجه به جدول بالا، مشاهده می‌شود که کلاس CSF همچنان چالش‌برانگیزترین بافت برای مدل است. با وجود Recall بالا (۹۳۴۲.۰)، Precision آن پایین‌تر (۴۷۹۸.۰) است که نشان می‌دهد مدل بیشتر نواحی واقعی CSF را شناسایی کرده اما بخش‌هایی از بافت‌های غیر CSF را نیز به اشتباه پیش‌بینی کرده است. برای بافت‌های GM و WM، مدل عملکرد بهتری دارد؛ Dice بالای این کلاس‌ها (۸۲۲۵.۰ برای GM و ۸۵۰۰.۰ برای WM) نشان می‌دهد که مدل توانسته نواحی بزرگتر و پیوسته‌تر را با دقت مناسبی بازسازی کند. دلیل ضعف در تشخیص CSF شامل موارد زیر است:

- **اندازه و پراکندگی بافت:** CSF نواحی کوچک و پراکنده دارد که باعث افزایش خطاهای مثبت و منفی می‌شود.
- **مرزهای ظریف با سایر بافت‌ها:** تشخیص مرز CSF با GM و WM دشوار است و شدت پیکسل‌های مشابه باعث کاهش دقت می‌شود.
- **توزیع داده‌ها:** تعداد پیکسل‌های CSF در مجموعه داده کمتر از GM و WM است، بنابراین مدل نمونه‌های کمتری برای یادگیری ویژگی‌های آن دارد.


نتیجه‌گیری

- مدل برای بافت‌های بزرگتر و پیوسته مانند GM و WM عملکرد مناسبی دارد.
- CSF به دلیل پراکندگی و مرزهای ظریف، همچنان چالش‌برانگیز است، اما Recall بالای آن نشان‌دهنده شناسایی اکثر نواحی واقعی است.
- میانگین Dice کل مدل حدود ۰.۸۲۶۲ است که نشان‌دهنده عملکرد خوب مدل در بازسازی کلی نقشه سگمنتیشن می‌باشد.





۵-۱



نتایج و ارزیابی نتایج

شبکه عملکرد مطلوبی در بخش‌بندی بافت‌های مغز داشته است. همپوشانی قابل توجه بین ماسک پیش‌بینی‌شده

و Truth Ground (حقیقت پایه) نشان‌دهنده دقت بالای مدل است.

نقاط قوت:

مناطق وسیع و پیوسته مربوط به ماده سفید (WM) و ماده خاکستری (GM) با دقت بالایی بخش‌بندی شده‌اند. خطاهای بخش‌بندی:

در برخی نواحی کوچک، برچسب بافت به اشتباه پیش‌بینی شده است (مانند جایگزینی CSF با GM یا WM و بالعکس).

مرزهای بین بافت‌ها (مانند مرز GM و WM دارای اندکی ناپیوستگی هستند که عمدتاً ناشی از اثر حجم جزئی (Partial Volume Effect) در تصاویر MRI می‌باشد.

مدل با موفقیت وظیفه بخش‌بندی را با صحت بالا انجام داده و نواقص موجود عمدتاً در سطح جزئیات رخ داده‌اند.

۲ تشخیص وسائل نقلیه با استفاده از Faster-RCNN بهبود یافته

در این گزارش نخست به معماری مطرح شده در مقاله می‌پردازیم، سپس به سوالات نظری مطرح شده پاسخ می‌دهیم. در ادامه توضیحی راجعه مجموعه داده و نحوه پیش‌پردازش آن می‌دهیم. در نهایت این داده را روی مدل Faster-RCNN پایتورچ آموزش می‌دهیم و معیارهای خواسته شده را نمایش می‌دهیم.

۱-۲ معماری مقاله

معماری ارائه‌شده در این مقاله با هدف تشخیص دقیق خودروها، به‌ویژه خودروهای کوچک و دور، طراحی شده است. این معماری از سه بخش اصلی تشکیل شده است: backbone برای استخراج ویژگی، شبکه‌ی RPN، و ماژول نوآورانه‌ی Context-Aware RoI Pooling که برای افزایش کیفیت پروپوزال‌های تولید شده توسط شبکه RPN به کار می‌رود. پس از این مرحله، یک طبقه‌بند عملیات نهایی تشخیص و تنظیم bounding box را انجام می‌دهد.

استخراج ویژگی

ورودی تصویر ابتدا وارد یک شبکه‌ی MobileNetV2 می‌شود که به‌عنوان backbone مدل عمل می‌کند. خروجی این شبکه، یک فیچر مپ است که اطلاعات معنایی لازم را برای مراحل بعدی فراهم می‌کند. دلیل انتخاب MobileNetV2، سبکی، سرعت بالا و توانایی آن در استخراج ویژگی‌های مناسب در محیط‌های زمانی-واقعی است. همچنین ویژگی شاخص آن این است که تصاویر نیاز به resize شدن ندارند و هر تصویری با هر ابعادی می‌توان به مدل داد. این باعث می‌شود تا تنظیم bounding boxها به هم نریزد.

(RPN)

به طور کلی ساختار RPN در معماری مقاله مشابه ساختارهای معمول RPN است. با این تفاوت که روی پروپوزال‌های خروجی الگوریتم soft-nms اجرا می‌شود. پس از استخراج ویژگی، شبکه‌ی RPN برای هر نقطه بر روی نقشه‌ی ویژگی مجموعه‌ای از anchorها را در سه مقیاس (۱۲۸، ۲۵۶ و ۵۱۲ پیکسل) و سه نسبت تصویر (۱:۱، ۲:۱ و ۱:۲) ایجاد می‌کند. این شبکه برای هر anchor امتیاز احتمال وجود جسم و نیز مقادیر تنظیم جعبه را پیش‌بینی می‌کند. خروجی RPN مجموعه‌ای از proposalهایی است که با استفاده از Soft-NMS خطی

فیلتر می‌شوند تا پیشنهادهای با کیفیت پایین حذف شده و نواحی محتمل‌تر باقی بمانند. این الگوریتم با تعریف معیار objectiveness پروپوزال‌هایی که بیشترین اشتراک را دارند را بهترینشان را انتخاب می‌کند. نتیجه‌ی این مرحله مجموعه‌ای از نواحی پیشنهادی است که برای پردازش دقیق‌تر به مرحله‌ی بعد ارسال می‌شوند.

ماژول Context-Aware RoI Pooling

RoI Pooling متداول در روش‌های کلاسیک مانند R-CNN، Faster R-CNN برای نواحی کوچک عملکرد ضعیفی دارد، زیرا هنگام تغییر اندازه به ابعاد ثابت، bounding box کوچک کشیده شده و مدل نمی‌تواند آن‌ها را تشخیص دهد. در این مقاله برای رفع این مشکل، ماژول Context-Aware RoI Pooling معرفی شده است. این روش بسته به ابعاد proposal نسبت به اندازه‌ی استاندارد خروجی (مثلاً 14×14 پیکسل)، از دو نوع عمل متفاوت استفاده می‌کند:

- اگر proposal بزرگتر از اندازه‌ی هدف باشد، از MaxPooling برای کوچک‌سازی استفاده می‌شود.
- اگر proposal کوچکتر باشد، از Deconvolution برای بزرگ‌سازی استفاده می‌شود.

در صورتی که proposal در یک بُعد کوچک و در بُعد دیگر بزرگ باشد، در هر جهت عمل مناسب pooling یا deconvolution اعمال می‌شود. کرنل‌های deconvolution به‌طور تطبیقی و بر اساس نسبت ابعاد ناحیه‌ی پیشنهادی به ابعاد خروجی تعیین می‌شوند. این روش موجب حفظ بهتر جزئیات نواحی کوچک، خصوصاً خودروهایی که در فاصله‌ی دور قرار دارند، می‌شود. همچنین باعث می‌شود تا اگرچه ابعاد تصاویر ممکن است متنوع باشد اما در نهایت به یک فیچر مپ با ابعاد یکسان برسیم

classifier

پس از اجرای Pooling، RoI Context-Aware خروجی‌های 14×14 به یک طبقه‌بند سبک‌وزن مبتنی بر MobileNet وارد می‌شوند. این طبقه‌بند شامل چند لایه‌ی Depthwise و Pointwise Convolution به همراه یک لایه‌ی Pooling برای فشردسازی نهایی ویژگی‌ها است. خروجی این بخش شامل دو سر مستقل است: یکی برای تشخیص کلاس خودرو و پس زمینه، و دیگری برای تنظیم دقیق مختصات bounding box. ساختار طبقه‌بند در مقاله توصیف شده است.

جمع‌بندی

ترکیب سه مؤلفه‌ی MobileNetV2، شبکه‌ی RPN و ماژول Context-Aware RoI Pooling، موجب ایجاد مدلی سبک‌وزن، سریع و بسیار دقیق برای تشخیص خودروها می‌شود. نوآوری اصلی مدل در نحوه‌ی پردازش نواحی کوچک است که به‌جای استفاده‌ی یکنواخت از pooling، از راهبرد تطبیقی برای بزرگسازي و حفظ اطلاعات استفاده می‌کند. این ساختار باعث افزایش چشمگیر دقت در تشخیص خودروهای کوچک و بهبود پایداری مدل در صحنه‌های شهری می‌شود.

۲-۲ سوالات نظری

۱-۲-۲ تفاوت NMS و Soft-NMS چیست؟

در معماری مقاله مورد نظر، مرحله پس‌پردازش پیشنهادهای RPN برای حذف پروپوزال‌های همپوشان اهمیت دارد. دو روش برای این کار وجود دارد: NMS و Soft-NMS. تفاوت‌های آن‌ها به شرح زیر است: روش NMS به صورت زیر عمل می‌کند:

۱. ابتدا تمام پیشنهادهای خروجی RPN بر اساس امتیاز احتمال وجود جسم مرتب می‌شوند.

۲. به صورت تکراری، پیشنهاد با بالاترین امتیاز (*winner*) انتخاب می‌شود.

۳. تمام پیشنهادهای دیگر که با *winner* دارای *IoU* بیشتر از آستانه T هستند، حذف می‌شوند.

بنابراین NMS روشی سخت‌گیرانه است و هر *proposal* که بیش از حد همپوشانی داشته باشد، کاملاً حذف می‌شود. این روش ممکن است برای اشیای نزدیک یا کوچک باعث کاهش دقت شود.

Soft-NMS به جای حذف کامل، امتیاز پیشنهادهای دارای همپوشانی بالا را کاهش می‌دهد:

۱. پیشنهاد با بالاترین امتیاز (*winner*) انتخاب می‌شود.

۲. برای هر *proposal* دیگر، امتیاز به صورت خطی کاهش می‌یابد:

$$\text{score}_i = \text{score}_i \times (1 - \text{IoU}(i, \text{winner}))$$

۳. اگر امتیاز کاهش یافته کمتر از حداقل آستانه T_s شود، آن پیشنهاد حذف می‌شود.

نتیجه این است که های-proposal نزدیک به هم حفظ می‌شوند ولی با وزن کمتر، و دقت تشخیص اشیای کوچک یا نزدیک به هم افزایش می‌یابد.

جدول مقایسه NMS و Soft-NMS

Soft-NMS	NMS	ویژگی
کاهش امتیاز حفظ می‌شود نرم (خطی)	حذف کامل کاهش می‌یابد سخت	رفتار با proposals با همپوشانی بالا دقت برای اشیای نزدیک یا کوچک نوع الگوریتم

جدول ۲: مقایسه NMS و Soft-NMS در مرحله پس‌پردازش RPN

۲-۲-۲ مزایا و معایب استفاده از Mobilenet در مقابل VGG16

در متن مقاله که ترجمه آن در زیر آمده است می‌خوانیم:

چارچوب اصلی Faster R-CNN از شبکه VGG-16 به عنوان شبکه پایه استفاده می‌کرد Liu و همکاران نشان دادند که تقریباً ۸۰٪ زمان اجرای پیش‌رو (forward time) صرف شبکه پایه می‌شود، بنابراین استفاده از یک شبکه پایه سریع‌تر می‌تواند سرعت کل چارچوب را به‌طور قابل توجهی بهبود بخشد. معماری MobileNet یک شبکه کارآمد است که عملیات کانولوشن را به یک *convolution depthwise* با فیلتر 3×3 و یک *pointwise convolution* با فیلتر 1×1 تقسیم می‌کند، که در عمل هم هزینه محاسباتی و هم تعداد پارامترها را کاهش می‌دهد. جدول ۳ مقایسه MobileNet و VGG-16 بر روی مجموعه داده ImageNet را نشان می‌دهد. همان‌طور که مشاهده می‌شود، MobileNet تقریباً به اندازه VGG-16 دقیق است، در حالی که ۳۲ برابر کوچک‌تر و ۲۷ برابر کم‌هزینه‌تر از نظر محاسباتی است.

جدول ۳: مقایسه مدل MobileNet با مدل VGG

مدل	ImageNet (%) دقت	میلیون (میلیون) Multiply-adds	پارامترها (میلیون)
MobileNet	۷۰.۶	۵۶۹	۴.۲
VGG-16	۷۱.۵	۱۵۳۰۰	۱۳۸

۳-۲-۲ معماری Context-aware RoI Pooling نسبت به RoI Pooling چه مشکلی را حل می‌کند؟

پاسخ را با نقل قول از مقاله می‌دهیم:

استفاده از RoI pooling از محاسبه مکرر لایه‌های کانولوشنی جلوگیری می‌کند و بنابراین می‌تواند زمان آموزش و تست را به طور قابل توجهی کاهش دهد. با این حال، اضافه کردن مقادیر تکراری به پروپوزال‌های کوچک مناسب نیست، به ویژه برای خودروهای کوچک، زیرا ممکن است ساختار اصلی خودروهای کوچک را از بین ببرد. علاوه بر این، اضافه کردن مقادیر تکراری برای پروپوزال‌های کوچک باعث نمایش نادرست ویژگی‌ها در forward propagation و انباشت خطا در backward propagation در طول فرایند آموزش می‌شود. بنابراین، عملکرد در شناسایی خودروهای کوچک کاهش می‌یابد.

برای تنظیم اندازه پروپوزال‌ها به اندازه ثابت بدون از بین بردن ساختار اصلی خودروهای کوچک و افزایش عملکرد روش پیشنهادی در شناسایی خودروهای کوچک، از context-aware RoI pooling (CARoI pooling) استفاده شده است. در فرایند CARoI pooling، اگر اندازه یک پروپوزال بزرگتر از اندازه ثابت نقشه ویژگی خروجی باشد، از max pooling برای کاهش اندازه پروپوزال به اندازه ثابت همانند RoI pooling سنتی استفاده می‌شود. اگر اندازه یک پروپوزال کوچکتر از اندازه ثابت نقشه ویژگی خروجی باشد، از عملیات deconvolution برای بزرگ کردن اندازه پروپوزال به اندازه ثابت استفاده می‌شود، همانطور که در فرمول زیر نشان داده شده است:

$$y_k = F_k \oplus h_k,$$

که در آن y_k نمایانگر نقشه ویژگی خروجی با اندازه ثابت است، F_k نمایانگر پروپوزال ورودی است و h_k کرنل عملیات deconvolution می‌باشد. اندازه کرنل برابر نسبت بین اندازه نقشه ویژگی خروجی و اندازه پروپوزال ورودی است.

علاوه بر این، هنگامی که عرض یک پیشنهاد بزرگتر از عرض ثابت فیچر مپ خروجی و ارتفاع آن کوچکتر از ارتفاع ثابت نقشه ویژگی خروجی باشد، از عملیات deconvolution همانند فرمول (۳) برای افزایش ارتفاع پیشنهاد استفاده می‌شود و از max pooling برای کاهش عرض آن بهره برده می‌شود. با استفاده از لایه CARoI pooling، اندازه پروپوزال‌ها به اندازه ثابت تنظیم شده است، در حالی که ویژگی‌های تمایزی از پروپوزال‌های کوچک همچنان قابل استخراج هستند.

با توجه به متن بالا می‌فهمیم که این ساختار کمک می‌کند تا پروپوزال به یک فیچر مپ با اندازه ثابت تبدیل

شود، این باعث می‌شود تا ویژگی‌هایی که منجر به تشخیص پروپوزال‌های کوچک می‌شود از دست نرود.

۳-۲ پیش‌پردازش داده‌ها

پیش‌پردازش مفصلی رو مجموعه داده‌های LSVH اجرا شده است که می‌توانید در فایل ژوپیتر ببینید. اما در این‌جا مختصری درباره داده‌ها توضیح می‌دهیم.

۱. ساختار پوشه‌ها و مسیرها: دیتاست شامل تصاویر و فایل‌های برچسب (annotation) در پوشه‌های جداگانه است:

LSVH_Data/LSVH/images/

LSVH_Data/LSVH/labels/

فایل images شامل تصاویری از بزرگراه‌هاست که انواع ماشین‌ها در حال رفت و آمد هستند. فایل labels شامل bounding box ها و تعلق آن به ۴ کلاس است. هر تصویر یک فایل txt. متناظر دارد که شامل برچسب‌های اشیا است.

۲. نگاشت کلاس‌ها و فیلترگذاری: برای تبدیل شناسه‌های عددی کلاس‌ها به برچسب‌های قابل خواندن، از نگاشت زیر استفاده می‌کنیم.:

```
CLASS_MAP = {1: "Car", 2: "Bus", 3: "Van", 4: "DontCare"}
```


کلاس DontCare را حذف می‌کنیم و خطوط نادرست یا کلاس‌های ناشناخته را پاک می‌کنیم.

۳. تقسیم‌بندی دیتاست: دیتاست به مجموعه‌های train و test بر اساس فایل‌های train.txt و test.txt تقسیم شد تا تصاویر آموزش و تست به صورت جداگانه استفاده شوند.

۴. مقیاس‌دهی / نرمال‌سازی (اختیاری): تصاویر به تنسور تبدیل و با میانگین و انحراف معیار MobileNet نرمال‌سازی شدند تا با مدل‌های تشخیص اشیا در torchvision سازگار باشند.

۲ تشخیص وسائل نقلیه با استفاده از Faster-RCNN بهبود یافته

در ادامه نمونه‌هایی از تصاویر خام و پیش‌پردازش‌شده خواهیم دید.



شکل ۱: داده خام



شکل ۲: داده پیش‌پردازش‌شده

۴-۲ آموزش روی مدل Faster-RCNN پایتورچ و نتایج

اگرچه ما مدل مقاله را پیاده‌سازی کردیم، اما به دلایلی مدل انتخاب شده بر پایه **R-CNN Faster** را از کتابخانه pytorch برگزیدیم. توصیف ساختار در قسمت قبل گذشت.

۱-۴-۲ فرآیند آموزش

مدل در ۲۵ اپوک آموزش داده شد و مراحل زیر در هر اپوک انجام شد:

۱. آموزش روی داده‌های **Train:** محاسبه Loss شامل:

- **loss_total:** مجموع تمام خطاها
- **loss_classifier:** خطای دسته‌بندی
- **loss_box_reg:** خطای مختصات جعبه‌ها
- **loss_objectness:** خطای شناسایی شیء توسط RPN
- **loss_rpn_box_reg:** خطای اصلاح جعبه‌های پیشنهادی RPN


۲. محاسبه **mAP@0.5** روی داده **Train:** هر ۵ اپوک، mAP روی داده آموزش محاسبه و ثبت شد تا عملکرد مدل روی داده دیده‌شده ارزیابی شود.

۳. محاسبه **Validation Loss** و **mAP@0.5:** بررسی تعمیم مدل روی داده دیده‌نشده و ثبت مقادیر در طول اپوک‌ها.


۴. تنظیم نرخ یادگیری: استفاده از LR Scheduler برای کاهش نرخ یادگیری در طول اپوک‌ها جهت پایدار شدن فرآیند آموزش.

۲-۴-۲ تحلیل نتایج

نمودارها به شرح زیر است:



شکل ۳: نمودار کاهش خطا



شکل ۴: نمودار $MAP@50$


۱. **نمودار Loss:** خطای مدل در ایپاک‌های آغازین سریع همگرا شده و تغییر چندانی نمی‌کند. نزدیکی خطای داده آموزشی و ارزیابی نشان‌دهنده این است که مدل overfit نشده است.

۲. **نمودار $mAP@50$:** افزایش ناگهانی mAP روی Train و Validation و تثبیت منحنی‌ها پس از ایپاک‌های میانی. عدد آن‌ها نشان‌دهنده این است که دقت مدل خوب و قابل قبول است.


۲ تشخیص وسائل نقلیه با استفاده از Faster-RCNN بهبود یافته

۳. نتیجه نهایی: مقدار $mAP@0.5$ روی مجموعه تست برابر با 0.6749 به دست آمد که نشان دهنده عملکرد قابل قبول مدل در شناسایی و دسته‌بندی وسایل نقلیه است.

برای فهم بهتر عملکرد مدل، به سراغ پاسخ مدل روی مجموعه داده آزمون می‌رویم:



شکل ۵: مقایسه پاسخ مدل با برجسب واقعی



شکل ۶: مقایسه پاسخ مدل با برجسب واقعی

همانطور که میبینیم مدل ماشین‌های نزدیک را به خوبی تشخیص می‌دهد، اما در تشخیص ماشین‌های خیلی دور یا بسیار نزدیک هم عاجز است. از اینجا متوجه می‌شویم که مقاله سعی در حل چه چالشی داشته، و معماری Context-aware RoI Pooling چگونه این چالش را برطرف می‌کند.

۲-۴-۳ جمع‌بندی

- استفاده از مدل **R-CNN Faster** با Backbone پیش‌آموزش‌دیده MobileNet امکان تشخیص دقیق اشیاء در تصاویر واقعی را فراهم کرد. همچنین باعث شد تا الگوریتم آموزش مدل خیلی زود همگرا شود و به دقت قابل قبولی برسد.
- پیش‌پردازش دقیق داده‌ها و تقسیم صحیح Train/Validation باعث شد مدل به خوبی تعمیم یابد و دچار overfitting نشود.
- محاسبه مداوم $mAP@.5$ و Loss در طول اپوک‌ها امکان انتخاب بهترین اپوک و بررسی عملکرد مدل را فراهم کرد.
- نتایج نشان داد که مدل می‌تواند به عنوان یک ابزار دقیق برای تشخیص و دسته‌بندی وسایل نقلیه در محیط‌های شهری مورد استفاده قرار گیرد. اما هنوز معماری ساده faster RCNN در تشخیص ماشین‌های دور یا بسیار نزدیک به هم عاجز است.