



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق
پاسخ تمرین شماره دو

دانشجویان:

سوال یک: احمد رضا نوپوش شماره دانشجویی ۶۱۰۳۰۱۱۹۴

سوال دو: رضا مردانی شماره دانشجویی: ۶۱۰۳۰۱۱۸۰

فهرست مطالب

۳	فهرست تصاویر
۴	فهرست جداول
۵	۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی
۵	۱-۱ آماده‌سازی مجموعه داده
۵	۱-۱-۱ انتخاب کلاس‌ها
۶	۱-۱-۲ افراز داده‌ها به سه مجموعه آموزش، ارزیابی و آزمون
۷	۲-۱ پیش‌پردازش داده‌ها
۷	۱-۲-۱ داده‌افزایی
۹	۳-۱ مدل AlexNet
۹	۱-۳-۱ پیاده‌سازی
۱۰	۲-۳-۱ نتایج و ارزیابی
۱۴	۴-۱ مدل INC-VGGN
۱۴	۱-۴-۱ پیاده‌سازی
۱۶	۲-۴-۱ نتایج و ارزیابی
۱۹	۵-۱ مقایسه
۲۱	۶-۱ پرسش‌ها
۲۱	۱-۶-۱ سوال اول
۲۱	۲-۶-۱ سوال دوم
۲۳	۳-۶-۱ سوال سوم
۲۴	۴-۶-۱ سوال چهارم
۲۵	۲ طبقه‌بندی صحنه در تصاویر سنجش از دور

فهرست تصاویر

۶	توزیع کلاس‌ها	۱
۸	bacterial Leaf Blight	۲
۸	Blast Leaf	۳
۸	Blight Sheath	۴
۸	Healthy Rice Leaf	۵
۱۰	AlexNet	۶
۱۳	AlexNet	۷
۱۶	INC-VGGN	۸
۱۸	INC-VGGN	۹
۱۹	مدل	۱۰
۲۰	مدل	۱۱
۲۰	میانگین معیارهای ارزیابی دو مدل	۱۲
۲۵	توازن کلاس‌ها و تقسیم داده‌ها به آموزش و آزمون	۱۳
۲۶	نمونه‌ای از تصاویر پس از داده‌افزایی	۱۴
۲۸	MLP با Accuracy و Loss	۱۵
۲۹	MLP	۱۶
۳۱	FC با Accuracy و Loss	۱۷
۳۲	FC	۱۸
۳۴	Accuracy و Loss با داده خام	۱۹
۳۵	ماتریس در هم‌ریختگی با داده خام	۲۰
۳۸	adam و MLP با Accuracy و Loss	۲۱
۳۹	adam و MLP	۲۲
۴۲	Accuracy و Loss پس از آزادسازی ۱۰ لایه آخر	۲۳
۴۲	ماتریس در هم‌ریختگی (Matrix Confusion) پس از آزادسازی ۱۰ لایه آخر	۲۴

فهرست جداول

۱	توزیع داده‌ها در بخش‌های مختلف	۶
۲	جزئیات معماری AlexNet پیاده‌سازی شده	۹
۳	جزئیات پارامترهای AlexNet پیاده‌سازی شده	۹
۴	ابر پارامترهای مدل AlexNet	۱۰
۵	جدول معیارهای ارزیابی بر مدل AlexNet	۱۱
۶	جدول معیارهای ارزیابی با جزئیات بیشتر بر مدل AlexNet	۱۱
۷	معماری مدل INC-VGGN	۱۴
۸	جزئیات پارامترهای مدل INC-VGGN	۱۵
۹	ابر پارامترهای مدل AlexNet	۱۵
۱۰	جدول معیارهای ارزیابی بر مدل INC-VGGN	۱۶
۱۱	جدول معیارهای ارزیابی با جزئیات بیشتر بر مدل INC-VGGN	۱۶
۱۲	مشخصات بهترین مدل انتخاب‌شده بر اساس دقت نهایی آزمون	۲۸
۱۳	مشخصات بهترین مدل انتخاب‌شده بر اساس دقت نهایی آزمون	۴۱

۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

در این تمرین به آموزش دو مدل CNN خواهیم پرداخت که وظیفه دارند تا بیماری یا آفت‌هایی که برگ برنج دچار می‌شود را شناسایی کنند. در این گزارش ابتدا به آمادسازی و پیش‌پردازش تصاویر برگ برنج می‌پردازیم و توضیحاتی راجع به Augmentation می‌دهیم. سپس مدل مشهور AlexNet را پیاده‌سازی خواهیم کرد و این مدل را روی داده‌ها آموزش می‌دهیم و نتایج آن را گزارش می‌کنیم و آن را ارزیابی می‌کنیم. بعد از آن به سراغ مدل معرفی شده در مقاله خواهیم رفت و پس از توضیحاتی درباره معماری آن، آن را آموزش خواهیم داد. پس از ارائه نتایج آموزش و ارزیابی، در نهایت این دو مدل را مقایسه خواهیم کرد و به سوالات مربوطه پاسخ خواهیم داد.


۱-۱ آمادسازی مجموعه داده

مجموعه داده مورد استفاده از پلتفرم Kaggle با نام “rice-disease-dataset” دریافت گردید. این مجموعه شامل ۶ کلاس مختلف از بیماری‌های برگ برنج می‌باشد که عبارتند از: Healthy، Sheath Blight، Leaf scald، Bacterial Leaf Blight و Brown Spot، Leaf Blast، Rice Leaf.

۱-۱-۱ انتخاب کلاس‌ها

برای انجام پروژه، کلاس **Healthy Rice Leaf** (برگ سالم برنج) به همراه سه کلاس دیگر به نام‌های **Leaf Blast**، **Bacterial Leaf Blight** و **Sheath Blight** به صورت تصادفی انتخاب شده‌اند. توزیع کلاس‌ها در نمودار زیر قابل مشاهده است. همانطور که می‌بینیم توزیع کلاس‌ها به صورت یکنواخت است.

۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی



شکل ۱: توزیع کلاس‌ها

۲-۱-۱ افراز داده‌ها به سه مجموعه آموزش، ارزیابی و آزمون

داده‌های هر چهار کلاس انتخاب شده به نسبت ۷۰-۱۵-۱۵ به سه بخش آموزش، ارزیابی و آزمون تقسیم

گردیدند. جدول زیر توزیع دقیق داده‌ها را در هر بخش نشان می‌دهد:

نام کلاس	داده‌های آموزش	داده‌های ارزیابی	داده‌های آزمون	جمع
برگ سالم برنج	۴۵۷ (70.0%)	۹۸ (15.0%)	۹۸ (15.0%)	۶۵۳
Blight Sheath	۴۴۲ (69.9%)	۹۵ (15.0%)	۹۵ (15.0%)	۶۳۲
Blight Leaf Bacterial	۴۴۵ (70.0%)	۹۵ (14.9%)	۹۶ (15.1%)	۶۳۶
Blast Leaf	۴۴۳ (69.9%)	۹۵ (15.0%)	۹۶ (15.1%)	۶۳۴

جدول ۱: توزیع داده‌ها در بخش‌های مختلف

همان‌طور که مشاهده می‌شود، توزیع داده‌ها در بین سه بخش تقریباً متوازن بوده و درصدهای اختصاص‌یافته

به هر بخش با دقت بالایی رعایت شده است. این توازن در تمامی کلاس‌ها برقرار می‌باشد که موجب می‌شود مدل

در معرض داده‌های همه کلاس‌ها به صورت متعادل قرار گیرد.

۲-۱ پیش‌پردازش داده‌ها

۱-۲-۱ داده‌افزایی

برای بهبود عملکرد مدل و جلوگیری از بیش‌برازش طبق دستورالعمل، از روش‌های داده‌افزایی بر روی مجموعه داده آموزش استفاده می‌کنیم. داده‌افزایی با ایجاد نمونه‌های جدید از داده‌های موجود، باعث افزایش تنوع داده‌های آموزشی می‌شود بدون آنکه نیاز به جمع‌آوری داده‌های جدید باشد. مقاله به استفاده از روش‌های داده‌افزایی اشاره کرده است:


Then, the image-processing techniques including grey transformation, image filtering, image sharpening and resizing, etc., are performed on the acquired images, and new sample images are generated to enrich the dataset using the data augmentation methods. For example, random rotation, flipping, and translation are utilized to enlarge the dataset.

بر اساس دستور العمل تمرین و مقاله، کد زیر برای داده‌افزایی پیاده‌سازی شد:


```
train_transform_alexnet = transforms.Compose([
    transforms.Resize((224, 224)), # Resize to 224x224
    transforms.RandomHorizontalFlip(p=0.5), # Random horizontal flip
    transforms.RandomVerticalFlip(p=0.5), # Random vertical flip
    transforms.RandomRotation(15), # Random rotation up to 15 degrees
    transforms.ColorJitter(brightness=0.2, contrast=0.2,
                           saturation=0.2, hue=0.1), # Color variations
    transforms.RandomAffine(degrees=0, translate=(0.1, 0.1)), # Random translation
    transforms.ToTensor(), # Convert to tensor
])
```

۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

با توجه به تصاویر برگ برنج، وارون‌سازی، چرخش و جابجایی ماهیت یا کلاس داده مورد نظر را عوض نمی‌کند. همچنین رنگ برگ‌های برنج بسته به شرایط آب‌وهوایی یا نوری می‌تواند کمی متفاوت باشد بنابراین تغییرات رنگی ملایم کلاس داده را عوض نخواهد کرد. همه این روش‌ها در مقاله گفته شده و ما به کار گرفته‌ایم. در ادامه نمونه‌هایی از تصاویر داده‌افزایی شده می‌بینیم.




شکل ۲: تصویر افزوده شده از کلاس bacterial Leaf Blight



شکل ۳: تصویر افزوده شده از کلاس Blast Leaf



شکل ۴: تصویر افزوده شده از کلاس Blight Sheath



شکل ۵: تصویر افزوده شده از کلاس Healthy Rice Leaf

۳-۱ مدل AlexNet

۱-۳-۱ پیاده‌سازی

در این پروژه، معماری AlexNet با تنظیمات اصلی و تطبیق لایه خروجی برای ۴ کلاس بیماری‌های برگ برنج پیاده‌سازی شده است. جدول زیر جزئیات کامل معماری را نشان می‌دهد:

پارامترها تعداد	خروجی شکل	لایه
34,944	[-1, 96, 55, 55]	Conv2d-1
0	[-1, 96, 55, 55]	ReLU-۲
0	[-1, 96, 27, 27]	MaxPool۲d-۳
614,656	[-1, 256, 27, 27]	Conv۲d-۴
0	[-1, 256, 27, 27]	ReLU-۵
0	[-1, 256, 13, 13]	MaxPool۲d-۶
885,120	[-1, 384, 13, 13]	Conv۲d-۷
0	[-1, 384, 13, 13]	ReLU-۸
1,327,488	[-1, 384, 13, 13]	Conv۲d-۹
0	[-1, 384, 13, 13]	ReLU-۱۰
884,992	[-1, 256, 13, 13]	Conv۲d-۱۱
0	[-1, 256, 13, 13]	ReLU-۱۲
0	[-1, 256, 6, 6]	MaxPool۲d-۱۳
0	[-1, 9216]	Dropout-۱۴
37,752,832	[-1, 4096]	Linear-۱۵
0	[-1, 4096]	ReLU-۱۶
0	[-1, 4096]	Dropout-۱۷
16,781,312	[-1, 4096]	Linear-۱۸
0	[-1, 4096]	ReLU-۱۹
16,388	[-1, 4]	Linear-۲۰

جدول ۲: جزئیات معماری AlexNet پیاده‌سازی شده

Total params	۵۸,۲۹۷,۷۳۲
Trainable params	۵۸,۲۹۷,۷۳۲
Non-trainable params	۰
Input size (MB)	۰.۵۷
Forward/backward pass size (MB)	۱۱.۰۸
Params size (MB)	۲۲۲.۳۹
Estimated Total Size (MB)	۲۳۴.۰۴

جدول ۳: جزئیات پارامترهای AlexNet پیاده‌سازی شده

۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی

این مدل را با استفاده از هایپرپارامترهای زیر بر داده آموزشی که قابلیت داده‌افزایی دارد آموزش دادیم.

Hyperparameter	Value
Epochs	۳۰
Learning Rate (lr)	۰,۰۱
Momentum	۰,۹
Weight Decay	5×10^{-4}
Batch Size	۳۲
Criterion	CrossEntropy
Optimizer	SGD

جدول ۴: ابرپارامترهای مدل AlexNet

تعداد اپیاک‌های فرآیند آموزش را طبق دستورالعمل ۳۰ قرار دادیم. از آنجایی که در حال آموزش یک مدل طبقه‌بند هستیم باید از Criterion های مربوط به طبقه‌بندی مانند CrossEntropy استفاده کنیم. ما از همین معیار خطا استفاده کردیم و در مقاله هم از همین معیار خطا استفاده شده است.

برای آموزش مدل نیز مانند مقاله بهینه‌ساز SGD را با ابرپارامترهای توصیف شده را به کار بردیم.

۲-۳-۱ نتایج و ارزیابی



شکل ۶: نمودار تغییرات خطا و دقت در مدل AlexNet

نمودار تغییرات خطا و دقت در مجموعه داده‌های آموزشی و ارزیابی به شرح بالاست. همانطور که مشاهده می‌شود با کاهش خطا و افزایش دقت در طی ۳۰ اپیاک، مدل به دقت ۸۰ درصدی بر روی داده‌های ارزیابی رسیده است.

جدول معیارهای ارزیابی به شرح زیر است.

Class	Accuracy	Sensitivity	Specificity
Bacterial Leaf Blight	۸۴.۱۶	۷۵.۰۰	۸۷.۲۰
Healthy Rice Leaf	۹۴.۸۱	۸۵.۷۱	۹۷.۹۱
Leaf Blast	۸۳.۳۸	۶۶.۶۷	۸۸.۹۳
Sheath Blight	۸۶.۷۵	۷۰.۵۳	۹۲.۰۷
Average	۸۷.۲۷	۷۴.۴۸	۹۱.۵۳

جدول ۵: جدول معیارهای ارزیابی بر مدل AlexNet

Class	Accuracy	Sensitivity	Specificity	Precision	F1 Score	TP	FP	FN	TN
Bacterial Leaf Blight	۸۴.۱۶	۷۵.۰۰	۸۷.۲۰	۶۶.۰۶	۷۰.۲۴	۷۲	۳۷	۲۴	۲۵۲
Healthy Rice Leaf	۹۴.۸۱	۸۵.۷۱	۹۷.۹۱	۹۳.۳۳	۸۹.۳۶	۸۴	۶	۱۴	۲۸۱
Leaf Blast	۸۳.۳۸	۶۶.۶۷	۸۸.۹۳	۶۶.۶۷	۶۶.۶۷	۶۴	۳۲	۳۲	۲۵۷
Sheath Blight	۸۶.۷۵	۷۰.۵۳	۹۲.۰۷	۷۴.۴۴	۷۲.۴۳	۶۷	۲۳	۲۸	۲۶۷
Average	۸۷.۲۷	۷۴.۴۸	۹۱.۵۳	۷۵.۱۲	۷۴.۶۸	—	—	—	—

جدول ۶: جدول معیارهای ارزیابی با جزئیات بیشتر بر مدل AlexNet

حال معیارهای ارزیابی را توضیح می‌دهیم و عملکرد مدل را بررسی می‌نماییم.

Accuracy (دقت): Accuracy نشان می‌دهد چه نسبتی از کل نمونه‌ها به‌درستی طبقه‌بندی شده‌اند.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

برای کلاس‌های مختلف، دقت را در جدول مشاهده می‌کنیم. بیشترین دقت مربوط به کلاس برگ سالم است (شاید به‌دلیل جداسازی آسان‌تر ویژگی‌های بصری)، و کمترین دقت مربوط به Blast Leaf است که بیانگر دشواری تشخیص صحیح آن است.

Sensitivity (Recall/حساسیت): نسبت نمونه‌های مثبتی که مدل تشخیص داده به کل نمونه‌های مثبت واقعی

را اندازه‌گیری می‌کند.

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

مقدار حساسیت کلاس‌ها از جدول قابل مشاهده است. همانطور که پیداست حساسیت کلاس Healthy Rice Leaf از بقیه کلاس‌ها بیشتر است و این به آن معناست که مدل برگ سالم برنج را به‌درستی تشخیص می‌دهد. از طرف

دیگر حساسیت کلاس Leaf Blast از سایر کلاس‌ها کمتر است و این یعنی تعداد قابل توجهی برگ بیمار از این کلاس وجود دارد که مدل توانایی تشخیص آن‌ها را ندارد.

Specificity نشان می‌دهد مدل چه نسبتی از نمونه‌های منفی واقعی را به‌درستی منفی تشخیص داده است..

$$\text{Specificity} = \frac{TN}{TN + FP}$$

همانطور که از جدول پیداست، این معیار برای کلاس Healthy Rice Leaf بسیار بالاست و این نشان می‌دهد مدل توانایی کاملی دارد که بگوید چه چیزی برگ برنج نیست.

Precision نشان می‌دهد از بین نمونه‌هایی که مدل مثبت پیش‌بینی کرده، چند درصد واقعاً مثبت بوده‌اند.

$$\text{Precision} = \frac{TP}{TP + FP}$$


این معیار برای کلاس‌های Leaf Blast و Bacterial Leaf Blight کمتر است و این نشان می‌دهد داده‌های زیادی بیماری‌شان به اشتباه تشخیص داده می‌شود در مقابل، مدل در پیش‌بینی برگ سالم بسیار دقیق عمل می‌کند و نشان می‌دهد مدل در تشخیص سالم بودن برگ برنج دقیق است.

F1 Score- میانگین هارمونیک Precision و Recall است و زمانی اهمیت دارد که بین FN و FP تعادل

لازم باشد.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

تحلیل کلی مدل بهترین عملکرد را در کلاس Healthy Rice Leaf دارد، زیرا هم ویژگی‌های این کلاس واضح‌تر هستند و هم میزان اشتباه‌های FP و FN در آن پایین است. ضعیف‌ترین عملکرد مربوط به Leaf Blast است که هم دقت، هم حساسیت، هم F1 پایین دارد. این نشان می‌دهد که مدل در استخراج ویژگی‌های مناسب برای این بیماری مشکل دارد. به‌طور کلی، مقادیر متوسط معیارها نشان می‌دهد که مدل عملکرد مناسبی دارد، اما بهینه‌سازی بیشتر مخصوصاً برای کلاس‌های Bacterial Leaf Blight و Leaf Blast ضروری است.



شکل ۷: ماتریس درهم‌ریختگی مدل AlexNet

برای بررسی دقیق‌تر عملکرد مدل، ماتریس درهم‌ریختگی نیز تحلیل می‌شود.

بیشترین و کمترین تشخیص درست: بر اساس مقادیر قطر اصلی ماتریس، بیشترین میزان تشخیص صحیح مربوط به کلاس Healthy Rice Leaf با مقدار $TP = 84$ است. این نتیجه سازگار با معیارهای قبلی است و نشان می‌دهد مدل در تفکیک برگ سالم عملکرد بسیار خوبی دارد. کمترین مقدار تشخیص درست مربوط به کلاس Leaf Blast با مقدار $TP = 64$ است که بیانگر دشوار بودن استخراج ویژگی‌های دقیق برای این بیماری و شباهت بالایی آن با سایر بیماری‌ها می‌باشد.

کلاس‌های پرتداخل (Misclassification): نتایج ماتریس نشان می‌دهد که بیشترین تداخل میان دو کلاس Leaf Blast و Bacterial Leaf Blight رخ داده است. مدل تعداد 19 نمونه از Leaf Blast را به اشتباه Bacterial Leaf Blight تشخیص داده و همچنین 15 نمونه از Bacterial Leaf Blight را به اشتباه Leaf Blast پیش‌بینی کرده است. این میزان بالای خطای دوطرفه نشان می‌دهد که این دو بیماری از نظر بصری

الگوهای بسیار مشابهی دارند.

پس از آن، تداخل قابل توجه میان کلاس‌های Sheath Blight و Bacterial Leaf Blight با مقادیر 17 و 8 مشاهده می‌شود. همچنین کلاس Leaf Blast با Sheath Blight نیز تداخل دارد، به‌طوری که 12 نمونه اشتباه به Sheath Blight و 7 نمونه به‌صورت برعکس طبقه‌بندی شده‌اند.

کمترین تداخل: کلاس Healthy Rice Leaf کمترین تداخل را با سایر کلاس‌ها دارد. مدل تنها تعداد کمی از نمونه‌های سالم را با بیماری‌ها اشتباه گرفته است (۱ نمونه به Bacterial، ۱۰ نمونه به Leaf Blast و ۳ نمونه به Sheath). این مسئله نشان می‌دهد که ویژگی‌های برگ سالم از نظر مدل قابل تشخیص‌تر و متمایزتر هستند.

۴-۱ مدل INC-VGGN

۱-۴-۱ پیاده‌سازی

مدل INC-VGGN که ساختار آن در جدول زیر قابل مشاهده است، مطابق مقاله پیاده‌سازی شده است.

Layer name	Type	Kernel size	Stride	Neuron size	Maps
Conv ^۱ _۱	Convolutional layer C ^۱	۳×۳	۱	۲۲۴×۲۲۴	۶۴
Conv ^۱ _۲	Convolutional layer C ^۲	۳×۳	۱	۲۲۴×۲۲۴	۶۴
Pool ^۱	Pooling layer P ^۱	۲×۲	۲	۱۱۲×۱۱۲	۶۴
Conv ^۲ _۱	Convolutional layer C ^۳	۳×۳	۱	۱۱۲×۱۱۲	۱۲۸
Conv ^۲ _۲	Convolutional layer C ^۴	۳×۳	۱	۱۱۲×۱۱۲	۱۲۸
Pool ^۲	Pooling layer P ^۲	۲×۲	۲	۵۶×۵۶	۱۲۸
Conv ^۳ _۱	Convolutional layer	۳×۳	۱	۵۶×۵۶	۲۵۶
Conv ^۳ _۲	Convolutional layer	۳×۳	۱	۵۶×۵۶	۲۵۶
Conv ^۳ _۳	Convolutional layer	۳×۳	۱	۵۶×۵۶	۲۵۶
Pool ^۳	Pooling layer P ^۲	۲×۲	۲	۲۸×۲۸	۲۵۶
Conv ^۴ _۱	Convolutional layer	۳×۳	۱	۲۸×۲۸	۵۱۲
Conv ^۴ _۲	Convolutional layer	۳×۳	۱	۲۸×۲۸	۵۱۲
Conv ^۴ _۳	Convolutional layer	۳×۳	۱	۲۸×۲۸	۵۱۲
Pool ^۴	Pooling layer P ^۲	۲×۲	۲	۱۴×۱۴	۵۱۲
Conv ^۲ _d _BN	Convolutional layer BN	۳×۳	۱	۱۴×۱۴	۵۱۲
Inception _۱	Inception module	—	—	۱۴×۱۴	۲۵۶
Inception _۲	Inception module	—	—	۱۴×۱۴	۲۵۶
Pool ^۴	Global pooling	—	—	۱×۱	۲۵۶
Output	Softmax regression	—	—	۱×۱×۵	۵

جدول ۷: معماری مدل INC-VGGN

پارامترهای مدل در جدول زیر قابل مشاهده است. توجه شود که ما مطابق مقاله چهار بلوک اول مدل VGGN-

۱۹ را با فریز کردن پارامترهای آن در اول مدل قرار داده‌ایم.

Total params	۳,۸۸۷,۶۸۴
Trainable params	۱,۵۶۲,۱۱۶
Non-trainable params	۲,۳۲۵,۵۶۸
Input size (MB)	۰.۵۷
Forward/backward pass size (MB)	۲۳۸.۸۸
Params size (MB)	۱۴.۸۳
Estimated Total Size (MB)	۲۵۴.۲۸

جدول ۸: جزئیات پارامترهای مدل INC-VGGN

از آنجایی که از مدلی آماده برای استخراج ویژگی از تصاویر استفاده می‌کنیم برای جلوگیری از مشکل

شیفت توزیع Dataloader جدیدی می‌سازیم مطابق با Dataloader قبلی با این تفاوت که مقادیر پیکسل‌ها را Normalize می‌کنیم.

```
transforms.Normalize(mean=[0.485, 0.456, 0.406],
std=[0.229, 0.224, 0.225])
```

حال مدل تعریف شده را با ابرپارامترهایی مشابه مدل قبلی آموزش می‌دهیم:

Hyperparameter	Value
Epochs	۳۰
Learning Rate (lr)	۰,۰۱
Momentum	۰,۹
Weight Decay	5×10^{-4}
Batch Size	۳۲
Criterion	CrossEntropy
Optimizer	SGD

جدول ۹: ابرپارامترهای مدل AlexNet



شکل ۸: نمودار تغییرات خطا و دقت در مدل INC-VGGN

نمودار تغییرات خطا و دقت در مجموعه داده‌های آموزشی و ارزیابی به شرح بالاست. همانطور که مشاهده می‌شود با کاهش خطا و افزایش دقت در طی ۳۰ اپیاک، مدل به دقت ۹۵ درصدی بر روی داده‌های ارزیابی رسیده است.

جدول معیارهای ارزیابی به شرح زیر است:

Class	Accuracy	Sensitivity	Specificity
Bacterial Leaf Blight	۹۴.۲۹	۸۶.۴۶	۹۶.۸۹
Healthy Rice Leaf	۹۹.۷۴	۱۰۰.۰۰	۹۹.۶۵
Leaf Blast	۹۵.۰۶	۹۳.۷۵	۹۵.۵۰
Sheath Blight	۹۸.۹۶	۹۵.۷۹	۱۰۰.۰۰
Average	۹۷.۰۱	۹۴.۰۰	۹۸.۰۱

جدول ۱۰: جدول معیارهای ارزیابی بر مدل INC-VGGN

Class	Accuracy	Sensitivity	Specificity	Precision	F1 Score	TP	FP	FN	TN
Bacterial Leaf Blight	۹۴.۲۹	۸۶.۴۶	۹۶.۸۹	۹۰.۲۲	۸۸.۳۰	۸۳	۹	۱۳	۲۸۰
Healthy Rice Leaf	۹۹.۷۴	۱۰۰.۰۰	۹۹.۶۵	۹۸.۹۹	۹۹.۴۹	۹۸	۱	۰	۲۸۶
Leaf Blast	۹۵.۰۶	۹۳.۷۵	۹۵.۵۰	۸۷.۳۸	۹۰.۴۵	۹۰	۱۳	۶	۲۷۶
Sheath Blight	۹۸.۹۶	۹۵.۷۹	۱۰۰.۰۰	۱۰۰.۰۰	۹۷.۸۵	۹۱	۰	۴	۲۹۰
Average	۹۷.۰۱	۹۴.۰۰	۹۸.۰۱	۹۴.۱۵	۹۴.۰۲	—	—	—	—

جدول ۱۱: جدول معیارهای ارزیابی با جزئیات بیشتر بر مدل INC-VGGN

حال معیارهای ارزیابی را توضیح می‌دهیم و عملکرد مدل را بررسی می‌نماییم.

Accuracy (دقت): بر اساس نتایج جدول، دقت مدل در تمامی کلاس‌ها بسیار بالا است. بیشترین دقت مربوط به کلاس Healthy Rice Leaf با مقدار 99.74 است که نشان می‌دهد مدل تقریباً تمام نمونه‌های سالم را به درستی تشخیص داده است. کمترین دقت مربوط به کلاس Bacterial Leaf Blight با مقدار 94.29 است که البته هنوز مقدار بالایی محسوب می‌شود و نشان می‌دهد مدل توانسته بخش عمده نمونه‌های این بیماری را درست شناسایی کند.


Sensitivity (Recall/حساسیت) حساسیت مدل برای کلاس‌های مختلف متفاوت است. بیشترین حساسیت مربوط به کلاس Healthy Rice Leaf با مقدار کامل ۱۰۰ است که نشان‌دهنده قابلیت بسیار بالای مدل در تشخیص درست برگ سالم است. کمترین حساسیت مربوط به Bacterial Leaf Blight با مقدار 86.46 و سپس Leaf Blast با مقدار 93.75 است. این مقدار نسبتاً پایین‌تر حساسیت برای Bacterial Leaf Blight نشان می‌دهد برخی نمونه‌های این بیماری (FN) توسط مدل نادیده گرفته شده‌اند.

Specificity معیار Specificity در همه‌ی کلاس‌ها بسیار بالا است و برای کلاس Sheath Blight مقدار کامل ۱۰۰ ثبت شده است. مقدار بالای Specificity به این معناست که مدل توانایی بسیار خوبی در تشخیص موارد منفی واقعی دارد. به‌طور خاص، Specificity کلاس Healthy Rice Leaf برابر 99.65 است که نشان می‌دهد مدل تقریباً هیچ برگ ناسالمی را به اشتباه سالم تشخیص نمی‌دهد.

Precision مقادیر Precision نشان می‌دهند که مدل در پیش‌بینی مثبت‌ها تا چه اندازه دقیق عمل کرده است. کلاس‌هایی که Precision بالاتری دارند شامل Healthy Rice Leaf با مقدار 98.99 و Sheath Blight با مقدار ۱۰۰ هستند. کمترین Precision مربوط به کلاس Leaf Blast با مقدار 87.38 است که نشان می‌دهد بخش قابل‌توجهی از نمونه‌های پیش‌بینی‌شده به عنوان این بیماری، در واقع مثبت واقعی نبوده‌اند (FP نسبتاً بالا).

Score: F۱- با توجه به مقادیر جدول، کلاس Healthy Rice Leaf بالاترین مقدار F۱ را با مقدار 99.49 دارد که نشان‌دهنده تعادل بسیار خوب بین Precision و Recall است. کمترین مقدار F۱ مربوط به Bacterial Leaf Blight با مقدار 88.30 است. همچنین کلاس Leaf Blast مقدار 90.45 دارد که نسبت به سایر کلاس‌ها کمتر است و نشان‌دهنده دشواری مدل در این طبقه‌بندی است.

تحلیل کلی به‌طور کلی مدل در طبقه‌بندی Healthy Rice Leaf بهترین عملکرد را دارد، زیرا هم حساسیت و هم دقت و هم F۱ در این کلاس تقریباً کامل هستند. ضعیف‌ترین عملکرد نسبی مربوط به Bacterial Leaf Blight و تا حدی Leaf Blast است، زیرا حساسیت و F۱ این کلاس‌ها از سایرین پایین‌تر است و نشان می‌دهد مدل در استخراج ویژگی‌های این بیماری‌ها با چالش بیشتری مواجه است. با وجود این، میانگین معیارها نشان‌دهنده عملکرد بسیار خوب مدل است.



شکل ۹: ماتریس درهم‌ریختگی مدل INC-VGGN

بیشترین و کمترین تشخیص درست: بر اساس مقادیر قطر اصلی ماتریس، بیشترین میزان تشخیص صحیح مربوط به کلاس Healthy Rice Leaf با مقدار $TP = 98$ است. این موضوع نشان می‌دهد که مدل در تشخیص برگ سالم دقت بسیار بالایی دارد و تقریباً تمامی نمونه‌های این کلاس را به‌درستی شناسایی کرده است. کمترین مقدار تشخیص درست مربوط به کلاس Bacterial Leaf Blight با مقدار $TP = 83$ است. اگرچه این مقدار همچنان بالا محسوب می‌شود، اما نسبت به سایر کلاس‌ها اندکی پایین‌تر است و نشان می‌دهد تشخیص این بیماری برای مدل دشوارتر بوده است.

کلاس‌های پرتداخل (Misclassification): بیشترین تداخل در این ماتریس بین دو کلاس Bacterial Leaf Blight و Leaf Blast مشاهده می‌شود. مدل تعداد 13 نمونه از Bacterial Leaf Blight را به اشتباه Leaf Blast تشخیص داده است. همچنین تعداد 6 نمونه از Leaf Blast به اشتباه به عنوان Bacterial Leaf Blight طبقه‌بندی شده‌اند. این خطای دوطرفه نشان می‌دهد که این دو کلاس از نظر ویژگی‌های بصری شباهت‌هایی با


یکدیگر دارند و تفکیک آن‌ها برای مدل تا حدی چالش‌برانگیز بوده است.

پس از آن، تداخل میان کلاس‌های Sheath Blight و Bacterial Leaf Blight نیز دیده می‌شود؛ به‌طوری که 3 نمونه از Sheath Blight به اشتباه Bacterial Leaf Blight و 1 نمونه از Sheath Blight به اشتباه Healthy Rice Leaf پیش‌بینی شده‌اند. در مجموع میزان این خطاها نسبتاً کم بوده و نشان می‌دهد مدل در تشخیص Sheath Blight عملکرد خوبی داشته است.

کمترین تداخل: کلاس Healthy Rice Leaf کمترین میزان تداخل را با سایر کلاس‌ها دارد. هیچ نمونه‌ای از کلاس‌های دیگر به اشتباه به عنوان برگ سالم پیش‌بینی نشده است، و تمام ۹۸ نمونه واقعی این کلاس نیز به‌درستی تشخیص داده شده‌اند. این موضوع بیانگر آن است که ویژگی‌های بصری برگ سالم بسیار متمایز بوده و مدل با اطمینان بالایی آن‌ها را از انواع بیماری‌ها تفکیک کرده است.

۵-۱ مقایسه

طبق تحلیل و ارزیابی‌هایی که تاکنون دیده‌ایم، واضح است که عملکرد مدل INC-VGGN به مراتب از عملکرد مدل AlexNet بهتر است. اما برای اطمینان بیشتر، نمودارهای زیر را تحلیل می‌کنیم




شکل ۱۰: نمودار تغییرات خطا و دقت در دو مدل

همانطور که از نمودار پیداست، دقت مدل INC-VGGN از مدل AlexNet بیشتر و خطای آن کمتر است. همچنین می‌بینیم که مدل INC-VGGN در تعداد اپیاک کمتری نسبت به مدل AlexNet برآزش پیدا کرده و روند آموزش آن بعد از اپیاک ۱۰ بسیار کند شده است اما می‌بینیم که روند آموزش مدل AlexNet در پایان اپیاک سی‌ام همچنان صعودی است. پس می‌توان نتیجه گرفت که سرعت یادگیری مدل INC-VGGN از مدل AlexNet

۱ تشخیص بیماری‌های برگ برنج با شبکه‌های عصبی


بیشتر است.



شکل ۱۱: ماتریس درهم‌ریختگی دو مدل

همانطور که از ماتریس‌های درهم‌ریختگی پیداست، عملکرد مدل INC-VGGN از AlexNet در همه

کلاس‌ها بهتر است.



شکل ۱۲: میانگین معیارهای ارزیابی دو مدل

۶-۱ پرسش‌ها

۱-۶-۱ سوال اول

بله، معماری پیشنهادی INC-VGGN به‌طور قابل توجهی بر سرعت یادگیری مدل تأثیر گذاشته و در مقایسه با AlexNet، دقت بسیار بالاتری را در دوره‌های آموزشی کمتری محقق کرده است.

عملکرد

- INC-VGGN از دقت آموزشی 57.92% در ایپاک اول شروع کرد.
- AlexNet تنها با دقت آموزشی 25.46% در ایپاک اول شروع کرد.
- تا ایپاک دوم، INC-VGGN به دقت آموزشی 78.68% رسید.
- در همین نقطه، AlexNet تنها در دقت آموزشی 23.95% بود.
- تا ایپاک پنجم، INC-VGGN به دقت آموزشی 87.13% دست یافت.
- AlexNet در ایپاک پنجم تنها در دقت آموزشی 33.63% بود.
- تا ایپاک دهم، INC-VGGN به دقت آموزشی 91.55% رسید.
- AlexNet در ایپاک دهم در دقت آموزشی 48.74% بود.
- INC-VGGN آموزشش در حدود ایپاک بیستم تقریباً تمام شده بود.
- AlexNet به‌طور تدریجی در طول تمام ۳۰ ایپاک آموزشی همواره در حال بهتر شدن بود.

۲-۶-۱ سوال دوم

استفاده از وزن‌های پیش‌آموزش‌داده‌شده در مدل INC-VGGN باعث بهبود چشمگیر عملکرد مدل شد. این موضوع از چند جنبه قابل تحلیل است:

۱. بهره‌گیری از سلسله‌مراتب ویژگی‌های از پیش آموخته‌شده

- لایه‌های اولیه‌ی پیش‌آموزش‌داده‌شده‌ی VGG (که در این مدل فریز شده‌اند) پیش‌تر توانسته‌اند ویژگی‌های پایین‌سطحی مثل لبه‌ها، بافت‌ها و رنگ‌ها را از مجموعه‌داده‌ی بسیار بزرگ ImageNet یاد بگیرند.
- لایه‌های میانی نیز به استخراج الگوهای پیچیده‌تر مانند شکل‌ها و اجزای اشیا مسلط شده‌اند.
- مزیت اصلی این است که برخلاف AlexNet که باید تمام این ویژگی‌ها را از ابتدا یاد بگیرد، مدل INC-VGGN با یک استخراج‌کننده‌ی ویژگی آماده و بسیار قدرتمند آموزش خود را آغاز می‌کند.

۲. کاهش پیچیدگی بهینه‌سازی

- در این مدل تنها ۱.۵۶ میلیون پارامتر آموزش داده می‌شود، در حالی که AlexNet باید ۵۸.۳ میلیون پارامتر را از ابتدا آموزش دهد.
- وزن‌های پیش‌آموزش‌داده‌شده نقطه‌ی شروع بسیار بهتری در فضای بهینه‌سازی فراهم می‌کنند.

۳. نقش منظم‌سازی (Regularization)

- فریز بودن وزن‌های پیش‌آموزش‌داده‌شده نوعی **منظم‌سازی ضمنی** ایجاد می‌کند و مانع بیش‌برازش روی داده‌های محدود بیماری برگ برنج می‌شود.

۴. بهره‌گیری از مزایای سازگاری دامنه (Domain Adaptation)

- تصاویر بیماری برگ، هرچند متفاوت از ImageNet هستند، اما ویژگی‌های سطح پایین و میانی آن‌ها (لبه، بافت، طیف رنگی) مشابه تصاویر طبیعی‌اند.
- بنابراین ویژگی‌های از پیش آموخته‌شده بدون نیاز به یادگیری مجدد قابل استفاده‌اند و تنها لازم است لایه‌های بالایی برای تخصصی‌سازی به بیماری‌ها آموزش ببینند.

۵. کارایی بالا در داده‌های کم

- در این مسئله تنها حدود ۱۰۰۰ تصویر اصلی موجود بود (حتی با افزایش تعداد داده از طریق Augmentation).
- AlexNet با داشتن ۵۸ میلیون پارامتر به داده‌ی بسیار بیشتری احتیاج دارد.
- اما INC-VGGN به دلیل تکیه بر دانش قبلی، با داده‌ی کم نیز عملکرد عالی نشان داده است.

در طراحی معماری INC-VGGN جایگزینی لایه‌های کانولوشنی انتهایی VGGNet با دو ماژول Inception یک تصمیم هدفمند و مؤثر بوده است که به‌طور چشمگیری فرآیند یادگیری مدل را بهبود داده است. این تغییر امکان استخراج ویژگی‌های چندمقیاسی از تصاویر برگ برنج را فراهم کرده است. لایه‌های استاندارد VGG تنها از فیلترهای 3×3 استفاده می‌کنند و بنابراین در هر لایه تنها قادر به تحلیل یک مقیاس از ویژگی‌ها هستند. با توجه به اینکه علائم بیماری‌های برگ در اندازه‌های متفاوتی ظاهر می‌شوند، استفاده از ساختار Inception که شامل مسیرهای موازی با فیلترهای 1×1 ، 3×3 و 5×5 است باعث شد مدل بتواند همزمان ویژگی‌های ریز و درشت را استخراج کند و در تشخیص تنوع بالای علائم بیماری عملکرد بهتری داشته باشد.

از منظر محاسباتی نیز این انتخاب مفید بوده است. در معماری مقاله، فیلترهای پرهزینه 5×5 با دو کانولوشن پشت‌سرهم 3×3 جایگزین شده‌اند که همان حوزه دید را ایجاد کرده اما پارامترهای کمتری مصرف می‌کنند. علاوه بر این، لایه‌های 1×1 در ماژول Inception برای کاهش ابعاد کانال‌ها به‌کار می‌روند و موجب می‌شوند عملیات پیچیده‌تر مانند 3×3 و 5×5 با هزینه محاسباتی کمتر انجام شود. ترکیب این تکنیک‌ها باعث شد مدل سبک‌تر، سریع‌تر و مقاوم‌تر در برابر بیش‌برازش باشد.

نتایج آموزشی نیز این مزیت را تأیید می‌کنند. مدل INC-VGGN در همان ابتدای آموزش به سرعت به دقت بالایی دست یافت (مثلاً دقت 78.68% در اپوک دوم)، در حالی‌که AlexNet با وجود پارامترهای بسیار بیشتر، پیشرفت کندتری داشت. این نشان می‌دهد که استخراج ویژگی‌های چندمقیاسی و مؤثر توسط Inception امکان همگرایی سریع‌تر و پایدارتر را فراهم کرده است. علاوه بر این، دقت نهایی مدل در داده‌های آزمون (حدود 97.01%) بیانگر توانایی قدرتمند معماری در تشخیص صحیح کلاس‌های بیماری حتی در شرایط پس‌زمینه پیچیده است.

به‌طور کلی، افزودن دو ماژول Inception باعث شد مدل بتواند ویژگی‌های ضروری برای تشخیص بیماری‌های برگ برنج را به‌صورت دقیق‌تر و کارآمدتر یاد بگیرد. این ساختار، ضمن کاهش بار محاسباتی، تنوع و غنای بیشتری در ویژگی‌های استخراج‌شده ایجاد کرده و توانایی تعمیم مدل را افزایش داده است. با توجه به ماهیت چندمقیاسی علائم بیماری‌های گیاهی، این انتخاب معماری نقش کلیدی در بهبود عملکرد و دقت بالای مدل نهایی داشته است.

در مدل‌های سنتی مانند VGG یا AlexNet، بیش از ۸۰ درصد پارامترهای شبکه در لایه‌های Fully Connected قرار دارند که این موضوع موجب افزایش زمان آموزش، مصرف زیاد حافظه و ایجاد پیچیدگی غیرضروری در مدل می‌شود. همان‌طور که در مقاله اشاره شده است، این حجم بالای پارامترها علاوه بر افزایش هزینه محاسباتی، خطر بیش‌برازش را نیز تقویت می‌کند؛ به‌ویژه در شرایطی که تصاویر برگ برنج در محیط‌های واقعی با پس‌زمینه‌های پیچیده، نور ناهمگون و نویزهای مختلف ثبت شده‌اند.


لایه Global Average Pooling با کاهش ابعاد مکانی هر نقشه ویژگی و تبدیل آن به میانگین تک‌پیکسل، نیاز به لایه‌های Fully Connected حجیم را از بین می‌برد. این فرایند باعث کاهش چشمگیر پارامترها می‌شود؛ به‌طوری که در مدل AlexNet بیش از پنجاه میلیون پارامتر در لایه‌های Fully Connected وجود دارد، اما در معماری INC-VGGN تنها حدود ۱۰۲۸ پارامتر برای لایه نهایی کافی است. این کاهش چشمگیر، ضمن سبک‌تر کردن مدل، موجب افزایش سرعت آموزش و بهبود کارایی حافظه شده است.

از نظر یادگیری مدل نیز استفاده از Global Pooling مزیت‌های مهمی دارد. برخلاف لایه‌های Fully Connected که ساختار فضایی ویژگی‌ها را از بین می‌برند، Global Average Pooling اطلاعات مکانی را تا مرحله نهایی حفظ می‌کند. این امر برای تشخیص الگوهای پراکنده بیماری در بافت برگ اهمیت ویژه‌ای دارد، زیرا مدل قادر است بر ویژگی‌های مرتبط با نواحی آسیب‌دیده تمرکز کند. حفظ ساختار فضایی همچنین باعث افزایش قابلیت تعمیم مدل می‌شود، چرا که مدل کمتر تمایل دارد به الگوهای بافتی یا نویزهای تصویری وابسته شود؛ مسئله‌ای که در داده‌های واقعی و غیرکنترل‌شده اهمیت زیادی دارد.

به‌طور کلی، استفاده از Global Pooling به جای لایه‌های تمام‌وصل موجب کاهش پارامترها، جلوگیری از بیش‌برازش، حفظ اطلاعات فضایی، افزایش پایداری مدل و کارایی محاسباتی شده است. این انتخاب معماری تأثیر مهمی در دقت بسیار بالای مدل INC-VGGN داشته و آن را نسبت به ساختارهای سنتی مانند AlexNet کارآمدتر و قابل‌اعتمادتر ساخته است.

۲ طبقه‌بندی صحنه در تصاویر سنجش از دور


پاسخ بخش ۱.۱



شکل ۱۳: توازن کلاس‌ها و تقسیم داده‌ها به آموزش و آزمون

پاسخ بخش ۲.۱

- روش‌های داده‌افزایی معرفی‌شده در بخش (۲-۲-۱) مقاله شامل چرخش، بزرگ‌نمایی، وارون‌سازی افقی و وارون‌سازی عمودی هستند. این روش‌ها باعث افزایش تنوع ظاهری نمونه‌ها شده و شبکه را نسبت به تغییرات دیدگاه مقاوم‌تر می‌کنند.
- ماهیت تصاویر سنجش‌ازدور به‌گونه‌ای است که معمولاً جهت دقیق اجسام اهمیت زیادی ندارد؛ بنابراین چرخش یا وارون‌سازی، ماهیت کلاس را تغییر نمی‌دهد و برچسب همچنان معتبر می‌ماند. این موضوع باعث می‌شود که داده‌افزایی بدون تولید نویز معنایی، مجموعه داده را غنی‌تر کند.



شکل ۱۴: نمونه‌ای از تصاویر پس از داده‌افزایی

پاسخ بخش ۳.۱

خلاصه معماری مدل SequentialClassifier

معماری استفاده‌شده شامل مراحل زیر است:

۱. استخراج ویژگی‌ها: خروجی شبکه Xception (فریز شده) استخراج می‌شود و به یک بردار 2048 بُعدی تبدیل می‌گردد.
۲. نرمال‌سازی: خروجی ویژگی‌ها توسط لایه FeatureNormalizer یکسان‌سازی مقیاس می‌شود.
۳. سیگموید: تمام مقادیر به بازه $[0,1]$ نگاشت می‌شوند.
۴. درآپ‌اوت: از لایه Dropout(0.4) برای جلوگیری از بیش‌برازش استفاده شده است.
۵. لایه نهایی: یک لایه Linear($2048 \rightarrow 21$) برای طبقه‌بندی نهایی.

نتایج آموزش مدل‌ها

- Adagrad $lr=0.01$ smooth 0.1
 - Final Train Accuracy: 92.02%

- Final Test Accuracy : 90.71%
- Final Train Loss : 0.9290
- Final Test Loss : 0.9221
- Adagrad lr=0.005 smooth 0.05
 - Final Train Accuracy: 90.51%
 - Final Test Accuracy : 91.43%
 - Final Train Loss : 0.7121
 - Final Test Loss : 0.6886

MODEL SELECTED (Highest Final Test Accuracy): Adagrad lr=0.005 smooth 0.05

Final Test Accuracy: 91.43%


جدول ۱۲: مشخصات بهترین مدل انتخاب‌شده بر اساس دقت نهایی آزمون

200	Size Batch
50	Epochs
Adagrad	Optimizer
0.005	Rate Learning
0.05	Smoothing Label
0.4	Rate Dropout
FeatureNormalizer	Layer Normalization
Sigmoid	Activation
Linear(2048 → 21)	Layer Classifier
Xception (Frozen)	Extractor Feature

پاسخ بخش ۴.۱

تحلیل نتایج آموزش مدل


۱. نمودار تغییرات خطا و دقت در طول آموزش



شکل ۱۵: نمودارهای Loss و Accuracy با MLP

در ابتدای آموزش، مقدار Loss به‌سرعت کاهش یافته و سپس در مقدار حدودی ۷.۰ پایدار شده است. همچنین مقدار Accuracy به‌سرعت افزایش یافته و در حدود ۹۰-۹۱٪ تثبیت شده است. این روند نشان می‌دهد که مدل از همان ابتدا شروع به یادگیری مؤثر کرده و در ادامه نیز بدون بروز بیش‌برازش، به همگرایی رسیده است.

۲. تحلیل ماتریس درهم‌ریختگی




شکل ۱۶: ماتریس درهم‌ریختگی با MLP

- بیشترین میزان تشخیص درست: کلاس‌های agricultural, beach, harbor, overpass, runway parkinglot, با دقت ۱۰۰٪.
- کمترین میزان تشخیص درست: buildings با ۱۴ نمونه صحیح از ۲۰، denseresidential و mediumresidential با ۱۷ نمونه صحیح از ۲۰.
- جفت‌کلاس‌های پرتداخل: buildings ↔ mediumresidential ↔ denseresidential ↔ golfcourse ↔ sparseresidential با کلاس‌های دارای الگوهای سبز مشابه.
- این نتایج نشان می‌دهد که کلاس‌هایی با بافت ظاهری مشابه بیشترین اشتباه را ایجاد می‌کنند.

۳. بررسی توان معماری پیشنهادی در سرعت یادگیری

همگرایی سریع Loss و افزایش پایدار Accuracy نشان می‌دهد معماری پیشنهادی (استفاده از Xception فریز شده و یک MLP سبک) توانسته سرعت یادگیری خوبی ایجاد کند. عدم فاصله زیاد بین نمودارهای آموزش و آزمون نشان می‌دهد که رفتار مدل پایدار بوده و دچار بیش‌برازش نشده است.

۴. دلیل استفاده از MLP جداگانه به جای لایه‌های Fully Connected سنتی




شکل ۱۷: نمودارهای Loss و Accuracy با FC

- Adagrad lr=0.01 smooth=0.1
 - Final Train Accuracy : 99.74%
 - Final Test Accuracy : 93.33%
 - Final Train Loss : 0.6956
 - Final Test Loss : 0.8679
- Adagrad lr=0.005 smooth=0.05
 - Final Train Accuracy : 99.90%
 - Final Test Accuracy : 92.86%
 - Final Train Loss : 0.3930
 - Final Test Loss : 0.5858

MODEL SELECTED (Highest Final Test Accuracy): Adagrad lr=0.01 smooth=0.1

Final Test Accuracy: 93.33%

- کاهش شدید تعداد پارامترها و سبکتر شدن طبقه‌بند.



شکل ۱۸: ماتریس در هم‌ریختگی با FC

- کاهش احتمال بیش‌برازش به‌خصوص در مجموعه‌های کوچک سنجش‌از‌دور.
- انعطاف‌پذیری بیشتر در استفاده از Dropout، نرمال‌سازی و توابع فعال‌سازی.
- سازگاری بهتر با نقش CNN به‌عنوان استخراج‌کننده ویژگی (Feature Extractor).

۵. نقش Pooling Average Global پیش از ورود ویژگی‌ها به MLP

- تبدیل حجم ویژگی ($H \times W \times C$) به بردار C-بعدی و کاهش ابعاد.
- حذف نیاز به لایه‌های Fully Connected بسیار بزرگ.
- افزایش مقاومت مدل نسبت به جابه‌جایی‌های مکانی در تصویر.
- کاهش پیچیدگی مدل و بهبود تعمیم‌پذیری.

۶. دلیل تأکید مقاله بر استفاده از بهینه‌ساز Adagrad برای MLP

- نرخ یادگیری تطبیقی و تنظیم جداگانه برای هر پارامتر.
- عملکرد عالی برای ویژگی‌های Sparse که در خروجی CNN رایج‌اند.
- مناسب برای شرایطی که فقط طبقه‌بند (MLP) آموزش می‌بیند و بخش CNN فریز است.
- نیاز اندک به تنظیم ابرپارامترها نسبت به Adam یا RMSProp.

پاسخ بخش ۵.۱

۱.۵.۱

Final Results


Optimizers Performance

- Adagrad lr=0.01 smooth=0.1
 - Final Train Accuracy : 87.02%
 - Final Test Accuracy : 87.14%
 - Final Train Loss : 1.0906
 - Final Test Loss : 1.0790
- Adagrad lr=0.005 smooth=0.05
 - Final Train Accuracy : 84.35%
 - Final Test Accuracy : 86.19%
 - Final Train Loss : 0.9930

– Final Test Loss : 0.9833


MODEL SELECTED (Highest Final Test Accuracy): Adagrad lr=0.01 smooth=0.1

Final Test Accuracy: 87.14%



شکل ۱۹: نمودارهای Loss و Accuracy با داده خام

۲ طبقه‌بندی صحنه در تصاویر سنجش از دور



شکل ۲۰: ماتریس در هم‌ریختگی با داده خام

مقایسه بخش‌های ۳.۱ و ۵.۱: نقش داده‌افزایی در بهبود عملکرد مدل

در این بخش، عملکرد مدل MLP در دو حالت بررسی می‌شود: (1) Training with Augmentation و (2) Training without Augmentation. مطابق بخش ۳.۱ و مطابق بخش ۵.۱. هدف، تحلیل تأثیر تکنیک‌های داده‌افزایی بر دقت نهایی و رفتار مدل است.

مقایسه عددی دقت مدل‌ها

نتایج نهایی نشان می‌دهد که مدل آموزش‌دیده با داده‌افزایی عملکرد بهتری روی داده‌های آزمون داشته است. بهترین مدل بخش ۳.۱ (با داده‌افزایی) دقت زیر را کسب کرده است:

$$Accuracy_{test}^{1,3} = 91.43\%$$

در حالی‌که بهترین مدل بخش ۵.۱ (بدون داده‌افزایی) دقت کمتری داشته است:

$$Accuracy_{test}^{1,5} = 87,14\%$$

بنابراین مقدار بهبود دقت ناشی از داده‌افزایی برابر است با:

$$\Delta = 91,43 - 87,14 = 4,29\%$$

این افزایش حدود ۴ تا ۵ درصدی نشان می‌دهد که داده‌افزایی نقش قابل‌توجهی در افزایش توان تعمیم مدل داشته است.

تحلیل تفاوت رفتار مدل‌ها

۱. تفاوت در روند همگرایی (Loss Curve) مشاهده‌ی منحنی‌های خطا نشان می‌دهد که:

- با داده‌افزایی، روند کاهش خطا نرم‌تر، پایدارتر و بدون نوسان‌های شدید است.
- مدل بدون داده‌افزایی سرعت یادگیری بیشتری در ابتدا دارد، اما به دلیل کمبود تنوع داده دچار بیش‌برازش و افزایش فاصله‌ی خطای آموزش و آزمون می‌شود.

۲. تحلیل عملکرد در کلاس‌ها (بر اساس Confusion Matrix) داده‌افزایی موجب شده است که:

- کلاس‌های بافت‌مشابه مانند buildings، mediumresidential، densresidential بهتر تفکیک شوند.
 - نرخ خطا در کلاس‌های دشوار کاهش یابد.
 - تعداد کلاس‌هایی که با دقت ۱۰۰ درصد تشخیص داده شده‌اند افزایش پیدا کند.
- در مقابل، مدل بدون داده‌افزایی:
- در تفکیک کلاس‌های نزدیک بهم عملکرد ضعیف‌تری دارد.

- اشتباهات بیشتری در ماتریس درهم‌ریختگی ایجاد می‌کند.
 - حساسیت بیشتری به تغییر شکل، زاویه و روشنایی تصاویر دارد.
۳. چرایی تأثیر مثبت داده‌افزایی علت اصلی تأثیر زیاد داده‌افزایی در داده‌های سنجش از دور این است که:
- جهت‌گیری و زاویه‌ی تصویربرداری در ماهواره ثابت نیست و چرخش یا انعکاس تصویر از نظر معنایی مشکلی ایجاد نمی‌کند.
 - با افزودن چرخش، وارونگی، بزرگ‌نمایی و تغییرات کوچک رنگی، مدل با نمونه‌های متنوع‌تر روبه‌رو شده و توانایی تعمیم آن افزایش می‌یابد.
 - داده‌افزایی به شکل مؤثر از بیش‌برازش جلوگیری می‌کند، زیرا مدل مجبور می‌شود الگوهای کلی‌تر را یاد بگیرد، نه جزئیات خاص نمونه‌های محدود.

جمع‌بندی

- به‌طور کلی، داده‌افزایی باعث شده است:
- دقت نهایی مدل حدود ۴ تا ۵ درصد افزایش یابد؛
 - مدل در کلاس‌های دشوار عملکرد پایدارتر و قابل‌اعتمادتر داشته باشد؛
 - منحنی خطا هموارتر شده و مدل کمتر دچار بیش‌برازش شود؛
 - تعمیم‌پذیری مدل بر روی داده‌های آزمون به میزان قابل توجهی افزایش پیدا کند.
- بنابراین، نتایج نشان می‌دهد که استفاده از داده‌افزایی در مسائل طبقه‌بندی تصاویر سنجش از دور یک ضرورت است و مدل بخش ۳.۱ به عنوان بهترین مدل انتخاب می‌شود.

پاسخ بخش ۲.۵.۱

- Adam lr=0.01 smooth 0.1


- Final Train Accuracy : 85.58%
- Final Test Accuracy : 86.67%
- Final Train Loss : 1.2026
- Final Test Loss : 1.1204

- Adam lr=0.005 smooth 0.1

- Final Train Accuracy : 88.33%
- Final Test Accuracy : 92.38%
- Final Train Loss : 1.0323
- Final Test Loss : 0.9399


Selected Model (Highest Test Accuracy): Adam lr=0.005 smooth 0.1

Final Test Accuracy: 92.38%



شکل ۲۱: نمودارهای Loss و Accuracy با MLP و adam

۲ طبقه‌بندی صحنه در تصاویر سنجش از دور



شکل ۲۲: ماتریس در هم‌ریختگی با MLP و adam

در این بخش، نقش بهینه‌ساز **Adagrad** در مدل **CNN-MLP** بررسی شد. برای این منظور، مدل همانند بخش ۳-۱ اجرا شد، اما این بار به جای **Adagrad** از بهینه‌ساز مدرن‌تر **Adam** استفاده گردید. سایر تنظیمات شامل نرخ یادگیری، روش هموارسازی تصاویر و ساختار مدل بدون تغییر باقی ماند تا تنها تفاوت مربوط به نوع بهینه‌ساز باشد.

مقایسه دقت نهایی

نتایج نشان داد دقت مدل با **Adam** کمی بالاتر از دقت مدل با **Adagrad** بوده است:

- دقت نهایی مدل با **Adagrad**: تقریباً ۴۳.۹۱٪

- دقت نهایی مدل با **Adam**: تقریباً ۳۸.۹۲٪

اگرچه این اختلاف زیاد نیست، اما نشان می‌دهد **Adam** توانسته وزن‌ها را بهتر بهینه کند.

آیا Adagrad انتخاب ضعیفی بوده است؟

خیر زیرا:

۱. **Adagrad** برای داده‌هایی با ویژگی‌های sparse یا گرادین‌های نامتعادل طراحی شده و همچنان به عنوان یک بهینه‌ساز قابل اعتماد محسوب می‌شود.

۲. در این مسئله، اختلاف دقت کم است؛ بنابراین عملکرد Adagrad همچنان مناسب بوده است.

۳. مزیت Adagrad در کاهش تطبیقی نرخ یادگیری است که در برخی مسائل باعث پایداری بیشتر هم می‌شود.

در این سناریو، Adam صرفاً همگرایی سریع‌تر و تنظیم بهتر نرخ یادگیری داشته و به همین دلیل دقت کمی بالاتر به دست آمده است.

آیا Adam می‌تواند نتایج بهتر بدهد؟

بله، دلایل آن عبارت‌اند از:

۱. Adam ترکیبی از **Momentum** و **RMSProp** است؛ بنابراین هم سرعت همگرایی بالاتری دارد و هم نوسانات گرادین را بهتر کنترل می‌کند.

۲. Adam به‌طور خودکار نرخ یادگیری مؤثر هر پارامتر را تنظیم می‌کند، بدون آنکه نرخ یادگیری خیلی سریع به صفر برسد (مشکل رایج Adagrad).

۳. در مدل‌هایی مانند CNN-MLP که گرادین‌ها پیچیده‌تر هستند، Adam معمولاً عملکرد پایدارتر و بهینه‌تری ارائه می‌دهد.

پاسخ بخش ۳.۵.۱

- Adam lr=0.001 smooth 0.1 Unfreez 10 last layers

– Final Train Accuracy : 93.05%

- Final Test Accuracy : 92.38%
- Final Train Loss : 0.8992
- Final Test Loss : 0.8900
- Adam lr=0.0005 smooth 0.1 Unfreez 10 last layers
 - Final Train Accuracy : 93.46%
 - Final Test Accuracy : 91.43%
 - Final Train Loss : 0.6098
 - Final Test Loss : 0.6385


Selected Model (Highest Test Accuracy): Adam lr=0.001 smooth 0.1 Unfreez 10 last layers

Final Test Accuracy: 92.38%


جدول ۱۳: مشخصات بهترین مدل انتخاب‌شده بر اساس دقت نهایی آزمون

200	Size Batch
50	Epochs
Adam	Optimizer
0.001	Rate Learning
0.1	Smoothing Label
0.4	Rate Dropout
FeatureNormalizer	Layer Normalization
Sigmoid	Activation
Linear(2048 → 21)	Layer Classifier
Xception (Unfreez 10 last layers)	Extractor Feature

۲ طبقه‌بندی صحنه در تصاویر سنجش از دور



شکل ۲۳: نمودارهای $Loss$ و $Accuracy$ پس از آزادسازی ۱۰ لایه آخر



شکل ۲۴: ماتریس درهم‌ریختگی ($Matrix\ Confusion$) پس از آزادسازی ۱۰ لایه آخر